Progetto di Architettura del Software e dei Dati

Appello del 27/02/2012

Studente: Simone Zaccaria

matricola: 718549

Testo del problema - 1

Un Comune vorrebbe realizzare un sistema per la gestione degli interventi in caso di emergenza neve. La struttura operativa comprende:

- 1. Un Centro di Coordinamento (CC).
- 2. Un Centro di Quartiere (CQ) per ogni quartiere della città.
- 3. Squadre di Quartiere (SQ) di spalatori, ciascuna con un Responsabile di Squadra (RS). Le SQ sono permanentemente assegnate ai quartieri e controllate dal CQ competente.
- 4. Mezzi Antineve (MA). I MA sono controllati da CC.
- 5. Un sistema esterno preesistente per la gestione dei mezzi pubblici (GP), che è in grado di rilevare la regolarità dei transiti dei mezzi e di segnalare eventuali situazioni di emergenza (blocco del mezzo) indicando la via in cui un'anomalia si verifichi. GP si appoggia su una mappa cartografica della città.
- 6. Vi è inoltre un sistema esterno preesistente per le previsioni meteo (PM), che è accessibile attraverso un servizio web.

Testo del problema - 2

CC ha il compito di:

- 1. Allertare entro le ore 24 di ogni giorno, in base alle previsioni meteo, CQ e MA, pianificando le attività dei MA.
- 2. Rivedere in tempo reale le attività dei MA, a fronte di segnalazioni di emergenza provenienti da GP o da CQ.
- 3. Comunicare a Enti esterni (servizio sanitario, forze dell'ordine, protezione civile) l'insorgere di eventuali situazioni di emergenza grave.

Il Centro di Quartiere CQ ha il compito di:

- 1. Pianificare dinamicamente le attività delle SQ in base alla situazione di specifiche vie rilevata dai RS, alla pianificazione dei MA e all'insorgere di situazioni di emergenza.
- 2. Interagire con i RS per comunicare la pianificazione e per acquisire informazioni sullo stato della viabilità e sulla presenza di eventuali situazioni di emergenza.

Testo del problema - 1

Si richiede di definire, utilizzando i formalismi opportuni:

- 1. l'architettura del problema in termini di informazioni e flussi informativi;
- 2. l'architettura logica in termini di componenti di elaborazione;
- 3. l'architettura concreta in termini di modalità di interazione fra componenti;
- 4. le infrastrutture hw e tlc di massima (tipo di device/pc/server e reti necessarie);
- 5. l'architettura di deployment;
- 6. l'architettura delle Basi Dati coinvolte. L'architettura deve prevedere la definizione di due basi di dati, una che rappresenta le esigenze informative del CC e dei CQ descritta per mezzo del modello Entita' Relazione con generalizzazioni, e l'altra che descrive le esigenze informative del GP per mezzo del modello relazionale. Le due basi di dati, considerate insieme, devono essere caratterizzate da alcune eterogeneita', che rendano il progetto non banale. E' richiesto di produrre lo schema integrato e i mapping Global as View tra schema integrato e schemi locali, rappresentati come viste SQL. E' inoltre richiesto di concepire due interrogazioni utili per il sistema, che visitino entrambe le basi di dati, e la loro rappresentazione prima dell'unfolding e dopo l'unfolding.
- 7. le modalità di interazione con i clienti e i relativi livelli di servizio.

Le scelte architetturali dovranno essere discusse presentandone le motivazioni ed evidenziando, ove opportuno, possibili scelte alternative con i relativi vantaggi e svantaggi. Si richiede in particolare di discutere qualitativamente (senza perciò un vero e proprio progetto) vantaggi e svantaggi della distribuzione nei CQ della base di dati centrale di cui alla domanda 6.

NON è richiesto di definire gli algoritmi di pianificazione. E' però richiesto che siano identificate le informazioni essenziali da essi utilizzate.

Ambiguità

- Chi segnala le emergenze
- Chi gestisce e valuta le emergenze
- Interazione con MA
- Interazione con sistemi preesistenti GP e PM
- Tempo reale per rivedere le attività di MA
- Come sono assegnate le squadre
- Come sono assegnati gli MA

Assunzioni – Quartieri e Vie

Un quartiere è un insieme di edifici ed infrastrutture che costituisce un'unità di urbanizzazione.

Una via può attraversare più quartieri.

Le vie sono suddivise in Sezioni, in modo che ogni sezione appartenga ad uno ed un solo quartiere (già presenti nel piano urbanistico delle città).

I quartieri, le vie e le sezioni delle vie sono specificate da una mappa cartografica della città.

Assunzioni – Rilevazioni ed Emergenze

Rilevazione: Segnalazione che viene fatta da un responsabile di squadra per riportare la situazione di una particolare Sezione.

Una rilevazione può specificare il grado di gravità rispetto all'emergenza neve e il grado che specifica la densità di traffico che è presente.

Una rilevazione può essere fatta anche per riportare una situazione positiva di una Sezione.

Assunzioni - Rilevazioni ed Emergenze 2

Un'Emergenza è una particolare situazione di difficoltà in una Sezione di una via.

Le Emergenze posso derivare da situazioni di gravità segnalate da CQ o da blocchi di mezzi.

Un'emergenza può essere segnalata da CQ quando:

- 1. Si hanno rilevazioni con un alto grado di gravità;
- 2. Rilevazioni con un grado medio-alto di gravità e un grado medio-alto di densità di traffico
- 3. Alta frequenza di rilevazioni di medio grado in uno stesso quartiere.

Un'emergenza derivante da un blocco di un mezzo è segnalata dal sistema preesistente GP

Esempio di Grado

Un esempio di grado che può essere definito per le rilevazioni è il seguente.

- 0 = Non c'è presenza di neve o precipitazioni che possono provocare difficoltà.
- 1 = Lieve presenza di neve solo sui lati della carreggiata.
- 2 = Moderata presenza di neve oltre la carreggiata e lieve presenza sul manto stradale.
- 3 = Moderata presenza di neve sul manto stradale che crea difficoltà di circolazione.
- 4 = Significativa presenza di neve sul manto stradale che rende molto difficoltosa la circolazione.
- 5 = Elevata presenza di neve sul manto stradale che rende impossibile la circolazione.
- → Nello stesso modo è possibile definire un grado anche per classificare la densità del traffico.

Assunzioni - Attività

Le squadre vengono assegnate a Sezioni delle vie del loro quartiere.

Un'attività di una Squadra assegnauna squadra ad una sequenza di Sezioni Vie.

I Mezzi Antineve (MA) vengono assegnati ai quartieri.

Un'attività di MA assegna ad un MA una sequenza di Quartieri.

Assunzioni - Attività 2

Una Pianificazione è l'insieme di tutte le ultime attività assegnate alle squadre o agli MA.

Il sistema comunica ai responsabili di squadra le attività della squadra corrispondente.

Il sistema comunica al Responsabile CC le attività degli MA.

Si assume che il CC, che controlla gli MA, abbia un sistema preesistente, o un canale di comunicazione che gli permette di interagire con gli MA (es. comunicazione via radio).

Sistemi Preesistenti

GP è un sistema preesistente.

PM è un sistema preesistente.

Si assume che è il Sistema in questione che inizia sempre le interazioni con questi sistemi/attori.

Tutti gli Enti Esterni, servizio sanitario, forze dell'ordine, protezione civile, sono definiti astrattamente come l'attore Ente.

Si assume che è il Sistema in questione che si preoccupa di segnalare agli Enti Esterni eventuali Emergenze Gravi.

Requisiti Funzionali

- Pianificare la giornata: quindi deve verificare le previsioni meteo ed in caso allerta i CQ e pianificare le attività dei MA.
- Gestire gli MA: segnalare che un MA ha concluso un'attività e rivedere in tempo reale le attività degli MA.
- Valutare le Emergenze e comunicare a Enti Esterni eventuali Emergenze Gravi

Requisiti Funzionali 2

- Interagire con GP per riconoscere eventuali emergenze dovute a blocchi di mezzi.
- Valutare le Rilevazioni riportate dalle Squadre.
- Notificare le Rilevazioni delle Squadre.
- Pianificare le Attività delle squadre e comunicarle ai responsabili di squadra.

Stime

- Circa 50 quartieri.
- Quartiere superficie di 2-8 Km²
- Circa 30 50 Mezzi Antineve
- Circa 3 8 Squadre per quartiere
- Un MA impiega circa 30-45 minuti per completare un'attività su un unico quartiere.
- Una Squadra impiega circa 15-30 minuti per completare un'attività su una Sezione.
- Un Responsabile Squadra nel caso peggiore effettua una Rilevazione ogni 10-15 minuti

Nota sulle Stime

Per definire le precedenti Stime ci si è basati su dati di città reali, tra cui le maggiori città italiane (come Milano, Torino, Roma, Napoli Palermo).

Le Stime rappresentano una media dei dati che sono stati acquisiti.


Le stime delle frequenze e dei ritardi sono state valutate considerando cosa succede in media nei casi peggiori.

Requisiti non Funzionali


- Rivedere le attività dei MA in Tempo Reale: valutando:
 - Tempi di spostamento
 - Tempi per le attività (s.v. Stime)
 - ⇒ Ordine di grandezza accettabile dei ritardi :
 Ordine dei minuti, ritardo accettabile 5-10 minuti
 - ⇒ Soft Real Time
- Pianificazione della giornata una volta al giorno prima delle ore 24.

Architettura del Problema


Casi d'Uso: Semplificato




Casi d'Uso: Dettagliato




Modello dei Dati




Pianifica Giornata




Gestisci MA




Valuta Emergenze




Preleva Emergenze Trasporti




Pianifica Attività Squadre



Riporta Rilevazione Sezione




Valuta Rilevazioni




Architettura Logica

Gestore Giornata




Gestore emergenze Trasporti



Soluzione 1

 Unico componente le attività che riguardano la gestione delle Emergenze, degli MA, delle rilevazioni e delle Squadre, con molteplicità
 <1..N> per ogni quartiere.

Suddivisione Orizzontale




Architettura del Logica

Simone Zaccaria, 718549

Footprint


Quartiere	0
Astrazione	100
Complessità	70
Frequenza	80
Delay	70
Localizzazione	90
ExtraFlow	50
IntraFlow	30
Condivisione	30



Soluzione 2


- Un unico componente per gestione emergenze e gestione Mezzi antineve
- Un componente con molteplicità 1..N per la gestione delle rilevazioni e delle squadre

Suddivisione Verticale e Orizzontale




Footprint

Quartiere	30
Astrazione	20
Complessità	80
Frequenza	70
Delay	90
Localizzazione	20
ExtraFlow	50
IntraFlow	10
Condivisione	80




- Un unico componente per la gestione delle Emergenze.
- Un unico componente per la gestione dei Mezzi Antineve.
- Un componente con molteplicità <1..N> per la gestione delle rilevazioni.
- Un componente con molteplicità <1..N> per la gestione delle Squadre.
- => Suddivisione orizzontale per livelli di astrazione



Footprint

Quartiere	50
Astrazione	10
Complessità	10
Frequenza	10
Delay	20
Localizzazione	10
ExtraFlow	100
IntraFlow	10
Condivisione	100




Soluzione Scelta

Soluzione scelta la Soluzione 3.


Permette di avere il risultato migliore sulle varie dimensioni.

Permette di ottenere il risultato migliore sulle dimensioni di maggior interesse, come la complessità, la frequenza e i quartieri.


Sequence – Pianifica Giornata




Sequence – Emergenze Trasporti




Sequence – Valuta Emergenze




Sequence – Gestisci MA




Sequence – Gestisci Squadre



Sequence – Valuta Rilevazioni



Architettura Concreta




• Pro:

- Rispetta la natura gerarchica del problema.
- Chiara separazione di interessi.
- Device dei RS non necessitano di potenza di calcolo.
- Basso fabbisogno in termini di larghezza di banda e disponibilità.

• Contro:

- Elevata complessità del Nodo Centrale: molti componenti eterogenei tra loro.
- Nodi di quartiere necessitano di media potenza di calcolo.

Soluzione 1 - Variante




Soluzione 1.1

Rispetto alla Soluzione 1.

Pro:

- La sede centrale non necessità di un unico nodo con elevata capacità di calcolo.
- Buona omogeneità dei componenti all'interno degli stessi nodi.



Architettura Concreta

Simone Zaccaria, 718549


• Pro:

- Rispetta la natura gerarchica del problema.
- Nodi dei quartieri necessitano solo di una bassa capacità di calcolo.
- Device dei RS non necessitano di potenza di calcolo.

Contro:

- GestoreSquadre più complesso perché deve essere in grado di pianificare le squadre di ogni quartiere.
- Maggiore fabbisogno in termini di larghezza di banda e disponibilità.
- Rischio di collo di bottiglia per la sede centrale
- Maggiore capacità di calcolo richiesta nella sede centrale

Soluzione 2 - Variante




Soluzione 2.1

Rispetto alla Soluzione 2.

Pro:

- la sede centrale non necessità di un unico nodo con elevata capacità di calcolo.
- Maggiore omogeneità dei componenti nei nodi stessi.




• Pro:

- Nodi dei quartieri necessitano solo di una medio-bassa capacità di calcolo
- Nodi della sede centrale necessitano solo di una media capacità di calcolo
- Rispecchia esattamente il livello di astrazione del problema.

Contro:

- Anche i Device dei RS necessitano di una medio-bassa capacità di calcolo.
- Maggiore fabbisogno in termini di larghezza di banda e disponibilità tra RS e Quartieri (rischioso in caso di emergenze)
- Rischio di "Collo di bottiglia" per i singoli quartieri.

Scelta: Soluzione 1.1



Scelta: Soluzione 1.1

Motivazioni:

- 1. Rispetta la natura gerarchica del problema.
- 2. Device dei RS non necessitano di potenza di calcolo.
- 3. Basso fabbisogno in termini di larghezza di banda e disponibilità => Minore Criticità.
- 4. Nodi nelle Sedi di Quartiere necessitano solo di una media capacità di calcolo.

Tecnologie – Comunicazione CQ \ CC

Soluzione Scelta: Sfruttare una Connessione ad Internet con servizio di livello Business, creando una rete dedicata (ad esempio creare una VPN).

Pro:

- La struttura per una connessione ad internet si può assumere che sia preesistente.
- Bassi costi.

Contro:

- Necessita di richiedere una connessione di livello Business che possa garantire determinati livelli di servizio.
- Costi maggiori rispetto ad una normale connessione.

Tecnologie – Comunicazione CQ \ CC

Alternativa: Sfruttare una Rete Wifi

Pro:

Struttura fisica dedicata.

Contro:

- Elevati costi per introdurre le nuove strutture necessarie.
- Costi di mantenimento.

Tecnologie - Comunicazione RS \ CQ

Soluzione Scelta: Comunicazione via Radio oppure semplice Comunicazione telefonica o entrambe.

Pro:

- Bassi Costi.
- Possibilità che una o entrambe le tecnologie siano preesistenti.

Contro:

 Necessaria un'interfaccia che permetta al sistema di inviare comunicazioni tramite queste tecnologie.

Tecnologie - Comunicazione RS \ CQ

Alternativa: Comunicazione telefonica tramite Smartphone e utilizzo del protocollo UMTS.

⇒ Utile solo nel caso in cui si decida di allocare il componente GestioneRilevazioni sul device degli RS.

Pro:

- Possibilità che questa tecnologia sia già disponibile.
- Necessaria solo se si decide di allocare un componente sul device degli RS.

Contro:

- Maggiore rischio di congestione della rete.
- Elevati costi se tecnologia non è già disponibile.

Tecnologie – Nodi di CQ e CC

- I Nodi di CQ necessitano solo di una mediobassa capacità di calcolo.
- ⇒Calcolatori con terminale di interfaccia utente di fascia media.

- CC necessita di Nodi di medio-alta capacità di calcolo
- ⇒Cluster di piccole dimensioni di Computer Server di fascia bassa.

Stima dei Costi

- Telefoni per gli RS (se necessari) = 50 x 5 x 20 = 5.000 €
- Nodi per CQ = 50 x 300 = 15.000 €
- Nodi per CC = 2 x 1.000 = 2.000 €

= 22.000 €

Stima totale delle strutture necessarie per il sistema.


Architettura dei Dati

Tavola delle Frequenze

Operazione	Tabelle Coinvolte	Frequenza	Note
Pianifica AttivitàMA	AttivitàMA, MezziAntineve, Quartiere, Emergenza	1/giorno	Sede Centrale
Rivedi AttivitàMA	AttivitàMA, MezziAntineve, Quartiere, Emergenza	6/ora	Sede Centrale
Pianifica AttivitàSquadra	AttivitàSquadra, Squadra, Emergenza, SezioneVia, Rilevazione, AttivitàMA	600/ora	Sede Quartiere
Aggiungi Emergenze Trasporti	Emergenza	10/ora	Sede Centrale
Valuta Rilevazioni	Rilevazione	2000/ora	Sede Quartiere
Aggiungi Emergenza	Emergenza	200/ora	Sede Quartiere

Soluzione Centralizzata

- Unico Schema Logico: quindi unica semantica
- Unica Base dati: quindi unico insieme di record
- => Nessuna forma di eterogeneità concettuale
- Unico schema fisico
- => Nessuna distribuzione
- Unico linguaggio di interrogazione => Unica modalità di accesso
- Unico sistema di gestione
- Unico amministratore dati => nessuna autonomia gestionale



Valutazione

Pro:


- Bassi costi e poche risorse
- Semplice
- Unico amministratore

Contro:

- Rischio collo di bottiglia
- Poco parallelismo
- No ridondanza

Soluzione Distribuita

- Unico Schema Globale Logico
- Distribuzione :
 - Risorse
 - Compiti
 - Frammentazione e replicazione
- Località
- Flessibilità
- Trasparenza di rete
- Trasparenza di frammentazione
- Trasparenza di replicazione



Risorse Frammentate

Frammentazione:

- SezioneVia
- Rilevazione
- Squadra
- AttivitàSquadra

Frammentazione orizzontale del primo tipo, per il principio di località, queste risorse vengono principalmente utilizzate dai Centri di Quartiere corrispondente.

Esempi di Frammentazione

- 1. SEL_{SezioneVia,Quartiere = "Quartiere1"} (SezioneVia)
- 2. SEL_{SezioneVia.Quartiere = "Quartiere1"} (Rilevazione JOIN

 ON Rilevazione.Via = SezioneVia.Nome SezioneVia)
- 3. SEL_{Quartiere = "Quartiere1"} (Squadra)
- 4. SEL_{QuartiereResponsabile = "Quartiere1"} (AttivitàSquadra)

Risorse Replicate

Risorsa Emergenza replicata, per il principio di località, in tutte le basi di dati perché viene acceduta con alta frequenza da tutti.

Necessità di protocolli per la mutual consistency (es. protocollo ROWA) e scelta di un protocollo distribuito per la gestione delle transazioni.

Valutazione

Pro:

- Località
- Modularità
- Prestazioni
- Resistenza ai guasti

Contro:

- Costi e Risorse
- Complessità

Scelta: SOLUZIONE DISTRIBUITA

A fronte di un incremento dei costi e delle risorse necessarie si ha un notevole miglioramento in termini di prestazioni (località e parallelismo).

Meno flusso dati sulla rete.

Si possono accettare ritardi nell'aggiornamento delle varie repliche (mutual consistency).

Inoltre, permette una grande flessibilità nell'ottica di possibili cambiamenti urbanistici rispetto ai quartieri.

Reliability & Avaiability

Reliability: probabilità che non si abbiano fallimenti in un determinato Δt .

Avaiability: probabilità che il sistema funzioni in un determinato Δt .

In questo sistema ci si focalizza su Avaiability.

 \Rightarrow Obiettivo:

Minimizzare MTTR (MeanTimeToRepair)

Ciclo di Vita dei Dati

Inoltre, si sottolinea la necessità nel contesto della Data Governance di un'attenzione particolare al controllo e gestione del ciclo di vita dei dati.

Alcuni Dati sono sensibili alle variazioni temporali ed è necessaria un'operazione di pulizia dei dati.

Esempio:

Le Rilevazioni che si riferiscono a situazioni di oltre 3 mesi passati possono non essere più significative per il sistema.

Recovery

Per garantire robustezza rispetto ai guasti risulta necessario avere a disposizione:

⇒ **Memoria Stabile:** Su cui memorizzare il **LOG** e memorizzare il **DUMP.**

⇒Protocollo **2PhaseCommited**, per gestire le politiche di commit, terminazione e recovery.

Integrazione

Integrazione ed Etoregenità

L'Integrazione ha come principale obiettivo quello di permettere agli utenti un accesso comune a più risorse di dati autonome ed eterogenee attraverso la presentazione di una visione unificata di questi dati.

Le *Eterogeneità* rappresentano le differenze presenti tra le risorse dati, in particolare le diverse rappresentazioni dello stesso concetto reale.


Approccio Scelto

Tipo di integrazione scelta:

EII (Enterprise Information Integration)

Approccio scelto:

Virtual Integration




Fonti a Disposizione

Si hanno due basi di dati che si vogliono integrare:

- 1. Base dati di CC e CQ (del suddetto sistema) =>descritta tramite il modello concettuale (ER).
- Base dati di GP
 =>descritta tramite il modello relazionale.

BD 1 – Modello Concettuale



BD 1 – Modello Relazionale

Tramite un'operazione di progettazione logica:

SezioneVia(Nome, #NumeriCivici, Lunghezza, Quartiere, Via, Metratura)

Quartiere(Nome, Quadrante, #Vie, Superficie)

Rilevazione(<u>Via</u>, <u>TimeStamp</u>, GradoNeve, GradoViabilità, QuartiereResponsabile, IDResponsabile)

Emergenza(<u>Via</u>, <u>TimeStamp</u>, <u>Data</u>, Grado, GradoViabilità, ViaRilevazione, TimeRilevazione, daQuartieri, daTrasporti)

Squadra(Quartiere, ID, #Squadra)

AttivitàSquadra(QuartiereResponsabile, IDResponsabile, Via, TimeStamp)

MezzoAntineve(<u>ID</u>, Tipo)

AttivitàMA(MezzoAntineve, Quartiere, TimeStamp)

BD 2 – Modello Relazionale

BloccoMezzi(Via, Data, Ora, GradoNeve, GradoMezzo)

Sezione(Nome, Quartiere, GradoTraffico, Metratura, #NumeriDispari, #NumeriPari, Quadrante)

Fermata(Nome, Tipo, Corso)

Percorso(Tipo, Partenza, Destinazione, Linea)

AssociazioneFermate(Fermata, TipoPercorso, Partenza, Destinazione)

PasssaggioFermate(MezzoCorsa, DataCorsa, oralnizioCorsa, Fermata, oraTeorica, oraReale)

Corsa(Mezzo, Data, oralnizioTeorica, Partenza, Destinazione, Tipo, oralnizioReale, oraFineTeorica, oraFineReale, Conclusa)

MezzoPubblico(ID, Tipo, diSuperficie)

PosizioneMezzo(<u>TimeStamp</u>, <u>Coordinate</u>, Mezzo, Corso)

Eterogeneità e Corrispondenze

Nella Fonte 1	Nella Fonte 2	Tipo	Scelta
SezioneVia	Sezione	Sinonimo	Si sceglie il nome SezioneVia
SezioneVia. #NumeriCivici	Sezione. #NumeriPari	Iperonimia	Si mantiene #NumeriCivici
SezioneVia. #NumeriCivici	Sezione. #NumeriDispari	Iperonimia	Si mantiene #NumeriCivici
Quartiere	Sezione.Quartiere	Eterogeneità strutturale	Si sceglie di rappresentare Quartiere come entità
SezioneVia.Via	Sezione.Corso	Sinonimi	Si sceglie Via
Emergenza.Grado	BloccoMezzo. GradoNeve	Sinonimi	Si sceglie Grado
Emergenza	BloccoMezzo	Iperonimia	Si mantiene Emergenza
Quartiere.Quadrante	Sezione.Quadrante	Corrispondenza	Si mantiene Quartiere.Quadrante
SezioneVia.metratura	Sezione.metratura	Omonimia	SezioneVia.metratura non viene riportara
SezioneVia.lunghezza	Sezione.metratura	Sinonimi	Si mantiene SezioneVia.lunghezza

Integrazione Simone Zaccaria, 718549

Linguaggio per Corrispondenze

S1.SezioneVia EQUAL S2.Sezione

WCI: S1.SezioneVia.Nome EQUAL S2.Sezione.Nome

WCP: S1.SezioneVia#NumeriCivici CONTAINS S2.Sezione.#NumeriPari;

S1.SezioneVia#NumeriCivici CONTAINS S2.Sezione.#NumeriDispari;

S1.SezioneVia.lunghezza EQUAL S2.Sezione.metratura;

S1.SezioneVia.Quartiere EQUAL S2.Sezione.Quartiere;

S1.Quartiere.Nome EQUAL S2.Sezione.Quartiere;

S1.Quartiere CORRESPOND S2.Sezione.Quartiere

WCI: S1.Quartiere.Nome EQUAL S2.Sezione.Quartiere

WCP: S1.Quartiere.Quadrante EQUAL S2.Sezione.Quadrante

S1.Emergenza CONTAINS S2.BloccoMezzo

WCI: S1.Emergenza.Via EQUAL S2.BloccoMezzo.Corso

S1.Emergenza.TimeStamp EQUAL S2.BloccoMezzo.Ora

S1.Emergenza.Data EQUAL S2.BloccoMezzo.Data

WCP: S1.Emergenza.GradoNeve EQUAL S2.BloccoMezzo.GradoNeve

S1.Emergenza.GradoViabilità EQUAL S2.BloccoMezzo.GradoTraffico

Passi dell'integrazione

- 1. Data Reverse Engineering
- 2. Integrazione Schemi
- 3. Progettazione Logica
- 4. Data Integration

Data Reverse Engineering

Passo 1.

Si ha il modello relazionale della Base di Dati di Gp.

⇒Si vuole ottenere il modello concettuale, tramite un'operazione di Reverse Engineering.

Relazionale BD 2

BloccoMezzi(Via, Data, Ora, GradoNeve, GradoMezzi)

Sezione(Nome, Quartiere, gradoTraffico, metratura, #NumeriDispari, #NumeriPari, Quadrante)

Fermata(Nome, Tipo, Corso)

Percorso(Tipo, Partenza, Destinazione, Linea)

AssociazioneFermate(Fermata, TipoPercorso, Partenza, Destinazione)


PasssaggioFermate(MezzoCorsa, DataCorsa, oralnizioCorsa, Fermata, oraTeorica, oraReale)

Corsa(Mezzo, Data, oralnizioTeorica, Partenza, Destinazione, Tipo, oralnizioReale, oraFineTeorica, oraFineReale, Conclusa)

MezzoPubblico(ID, Tipo, diSuperficie)

PosizioneMezzo(<u>TimeStamp</u>, <u>Coordinate</u>, Mezzo, Corso)

Concettuale BD 2



Integrazione di Schemi


Passo 2.

Si Identificano i concetti comuni tra i due schemi concettuali.


Si integrano i due schemi concettuali in un solo globale, integrando le parti comuni.

⇒Si ricava lo schema globale concettuale e si definiscono i mapping tra schema globale e schemi Locali.


Concettuale BD 1



Concettuale BD 2




Schema Globale Concettuale



I **Mapping** sono delle viste in SQL che permettono di mettere in relazione gli schemi locali con lo schema globale.

Approccio scelto: GAV (Global As View)



Create view Squadra as

SELECT Squadra.Quartiere as Quartiere,

Squadra.ID as ID,

Squadra.#Squadra as #Squadra

FROM S1.Squadra

Create view AttivitàSquadra as

SELECT AttivitàSquadra.QuartiereResponsabile as QuartiereResponsabile,

AttivitàSquadra.IDSquadra as IDSquadra,

AttivitàSquadra.Via as Via,

AttivitàSquadra.TimeStamp as TimeStamp

FROM S1.AttivitàSquadra

Create view MezzoAntineve as

SELECT MezzoAntineve.ID as ID,

MezzoAntineve.Tipo as Tipo

FROM S1.MezzoAntineve

Create view AttivitàMA as

SELECT AttivitàMA.MezzoAntineve as MezzoAntineve,

AttivitàMA.Quartiere as Quartiere,

AttivitàMA.TimeStamp as TimeStamp

FROM S1.AttivitàMA

Create view Rilevazione as

SELECT Rilevazione. Via as Via,

Rilevazione.TimeStamp as TimeStamp, Rilevazione.GradoNeve as GradoNeve,

Rilevazione.GradoViabilità as GradoViabilità,

Rilevazione.QuartiereResponsabile as QuartiereResponsabile,

Rilevazione.IDResponsabile as IDResponsabile

FROM S1. Rilevazione

Create view Fermata as

SELECT Fermata. Nome as Nome.

Fermata. Tipo as Tipo,

Fermata.Corso as Corso

FROM S1.Fermata

Create view Percorso as

SELECT Percorso. Tipo as Tipo,

Percorso.Partenza as Partenza,

Percorso. Destinazione as Destinazione,

Percorso.Linea as Linea

FROM S2.Percorso

Create view AssociazioneFermate as

SELECT AssociazioneFermate.Fermata as Fermata,

AssociazioneFermate.TipoPercorso as TipoPercorso,

AssociazioneFermate.Partenza as Partenza.

AssociazioneFermate.Destinazione as Destinazione

FROM S2.AssociazioneFermate

Create view MezzoPubblico as

SELECT MezzoPubblico.ID as ID,

MezzoPubblico.Tipo as Tipo,

MezzoPubblico.diSuperficie as diSuperficie

FROM S2.MezzoPubblico WHERE diSuperficie = True

Create view Corsa as

SELECT Corsa.Mezzo as Mezzo,

Corsa.Data as Data,

Corsa.oralnizioTeorica as oralnizioTeorica.

Corsa.Partenza as Partenza.

Corsa. Destinazione as Destinazione.

Corsa. Tipo as Tipo,

Corsa.oralnizioReale as oralnizioReale,

Corsa.oraFineTeorica as oraFineTeorica,

Corsa.oraFineReale as oraFineReale,

Corsa.Conclusa as Conclusa

FROM (S2.Corsa INNER JOIN S2.MezzoPubblico)

ON S2.Corsa.Mezzo = S2.MezzoPubblico.ID

WHERE diSuperficie = True

Create view PosizioneMezzo as

SELECT PosizioneMezzo.TimeStamp as TimeStamp,

PosizioneMezzo.Coordinate as Coordinate.

PosizioneMezzo.Mezzo as Mezzo,

PosizioneMezzo.Corso as Corso

FROM (S2.PosizioneMezzo JOIN S2.Mezzo)

ON S2.PosizioneMezzo.Mezzo = S2.Mezzo.ID

WHERE S2.PosizioneMezzo.diSuperficie = True

Crete view SezioneVia as

SELECT SezioneVia.Nome as Nome,

SezioneVia.Quartiere as Quartiere,

SezioneVia.#NumeriCivici as #NumeriCivici,

SezioneVia.Via as Via,

SezioneVia.Lunghezza as Lunghezza,

'O' as GradoTraffico

FROM S1.SezioneVia

UNION

SELECT Sezione. Nome as Nome,

Sezione.Quartiere as Quartiere,

SUM(Sezione.#NumeriDispari, Sezione.#NumeriPari) as #NumeriCivici,

Sezione. Via as Via,

Sezione. Metratura as Lunghezza,

Sezione.GradoTraffico as GradoTraffico

FROM (S2.Sezione INNER JOIN S1.SezioneVia) ON

S2.Sezione.Nome = S1.SezioneVia.Nome

Create view Quartiere as

SELECT Quartiere. Nome as Nome,

Quartiere.Quadrante as Quadrante,

Quartiere.#Vie as NumeroVie,

Quartiere. Superficie as Superficie

FROM S1.Quartiere

UNION

SELECT Sezione.Quartiere as Nome.

Sezione.Quadrante as Quadrante,

Sezione. #Vie as NumeroVie.

Sezione. Superficie as Superficie

FROM (S2.Sezione INNER JOIN S1.Quartiere) ON

S2.Sezione.Quartiere = S1.Quartiere.Nome

Create view Emergenza as

SELECT Emergenza. Via as Via,

Emergenza.Data as Data,

Emergenza. TimeStamp as TimeStamp,

Emergenza Grado as Grado,

Emergenza.GradoViabilità as GradoViabilità,

Emergenza.daQuartieri as daQuartieri, Emergenza.daTrasporti as daTrasporti,

Emergenza. Via Rilevazione as Via Rilevazione, Emergenza. Time Rilevazione as Time Rilevazione

FROM S1.Emergenza

UNION

SELECT BloccoMezzo.Via as Via,

BloccoMezzo.Data as Data,

BloccaMezzo.Ora as TimeStamp, BloccoMezzo.GradoNeve as Grado.

BloccoMezzo.GradoMezzi as GradoViabilità,

O as daQuartieri, 1 as daTrasporti

NULL as ViaRilevazione,
NULL as TimeRilevazione

FROM ((((BloccoMezzo JOIN Sezione) ON BloccoMezzo.Via = Sezione.Nome)

JOIN PosizioneMezzo) ON Quartiere = PosizioneMezzo.Corso)

JOIN MezzoPubblico) ON Mezzo = MezzoPubblico.ID)

WHERE diSuperficie = T

Progettazione Logica

Passo 3.

Dallo schema concettuale Globale si ricava lo schema logico Globale, nel modello relazionale.

Schema Logico Globale

Squadra(Quartiere, ID, #Squadra)

AttivitàSquadra(QuartiereResponsabile, IDResponsabile, Via, TimeStamp)

MezzoAntineve(ID, Tipo)

AttivitàMA(MezzoAntineve, Quartiere, TimeStamp)

Rilevazione(Via, TimeStamp, GradoNeve, GradoViabilità, QuartiereResponsabile, IDResponsabile)

Fermata(Nome, Tipo, Corso)

Percorso(Tipo, Partenza, Destinazione, Linea)

AssociazioneFermate(Fermata, TipoPercorso, Partenza, Destinazione)

PasssaggioFermate(MezzoCorsa, DataCorsa, oralnizioCorsa, Fermata, oraTeorica, oraReale)

Corsa(Mezzo, Data, oralnizioTeorica, Partenza, Destinazione, Tipo, oralnizioReale, oraFineTeorica, oraFineReale, Conclusa)

MezzoPubblico(ID, Tipo, diSuperficie)

PosizioneMezzo(TimeStamp, Coordinate, Mezzo, Corso)

SezioneVia(Nome, Quartiere, #NumeriCivici, Via, Lunghezza, GradoTraffico)

Quartiere(Nome, Quadrante, NumeroVie, Superficie)

Emergenza(Via, Data, TimeStamp, Grado, GradoViabilità, daQuartieri, daTrasporti, ViaRilevazione, TimeRilevazione)

Integrazione Dati

Passo 4.

L'integrazione dati è una tecnica per il miglioramento della qualità dei dati.

Due possibili approcci:

- 1. Gestire l'integrazione dei dati nei mapping stessi (es. per tuple con lo stesso identificatore, decidere cosa prendere).
- 2. Record Linkage.

Integrazione Dati a livello Mapping

Alcuni semplici esempi di integrazione di dati a livello mapping.

Idea Chiave: Per le tuple con uno stesso identificatore si determina come scegliere i valori degli altri attributi.

Esempio 1

Crete view SezioneVia as

SELECT Nome, COALESCE(Quartiere), MIN(NumeriCivici),

AVERAGE(Lunghezza), COALESCE(Via),

MAX(GradoTraffico)

SELECT SezioneVia.Nome as Nome,

SezioneVia.Quartiere as Quartiere,

SezioneVia.#NumeriCivici as #NumeriCivici,

SezioneVia.Via as Via,

SezioneVia.Lunghezza as Lunghezza,

'O' as GradoTraffico

FROM S1.SezioneVia

UNION

SELECT Sezione. Nome as Nome.

Sezione.Quartiere as Quartiere,

SUM(Sezione.#NumeriDispari, Sezione.#NumeriPari) as #NumeriCivici,

Sezione. Via as Via,

Sezione. Metratura as Lunghezza,

Sezione.GradoTraffico as GradoTraffico

FROM (S2.Sezione JOIN S1.SezioneVia) ON

S2.Sezione.Nome = S1.SezioneVia.Nome

GROUP BY Nome

Esempio 2

```
Create view Quartiere as
SELECT
         Nome,
         COALESCE(Quadrante),
         MIN(NumeroVie),
         AVERAGE(Superficie)
        SELECT Quartiere. Nome as Nome,
                         Quartiere.Quadrante as Quadrante.
                         Quartiere. #Vie as Numero Vie.
                         Quartiere. Superficie as Superficie
        FROM S1.Quartiere
    UNION
        SELECT Sezione.Quartiere as Nome.
                         Sezione.Quadrante as Quadrante.
                         Sezione. #Vie as NumeroVie.
                         Sezione. Superficie as Superficie
        FROM (S2.Sezione INNER JOIN S1.Quartiere) ON
                         S2.Sezione.Quartiere = S1.Quartiere.Nome
GROUP BY Nome
```

Esempio 3

Create view Emergenza as

SELECT Via, Data, TimeStamp, MAX(Grado), MAX(GradoViabilità), MAX(daQuartieri), MAX(daTrasporti),

COALESCE(ViaRilevazione), COALESCE(TimeRilevazione)

SELECT Emergenza. Via as Via,

Emergenza.Data as Data,

Emergenza. TimeStamp as TimeStamp,

Emergenza.Grado as Grado,

Emergenza.GradoViabilità as GradoViabilità,

Emergenza.daQuartieri as daQuartieri, Emergenza.daTrasporti as daTrasporti,

Emergenza. Via Rilevazione as Via Rilevazione,

Emergenza. Time Rilevazione as Time Rilevazione

FROM S1.Emergenza

UNION

SELECT BloccoMezzo.Via as Via,

BloccoMezzo.Data as Data,

BloccaMezzo.Ora as TimeStamp, BloccoMezzo.GradoNeve as Grado,

BloccoMezzo.GradoMezzi as GradoViabilità,

O as daQuartieri,

1 as daTrasporti

NULL as ViaRilevazione,

NULL as TimeRilevazione

FROM [[[[BloccoMezzo JOIN Sezione] ON BloccoMezzo.Via = Sezione.Nome]

JOIN PosizioneMezzo) ON Quartiere = PosizioneMezzo.Corso)

JOIN MezzoPubblico] ON Mezzo = MezzoPubblico.ID]

WHERE diSuperficie = T

GROUP BY Via, TimeStamp, Data, Grado, GradoViabilità, Rilevazione, daTrasporti

Record Linkage

Problema: lo stesso oggetto del mondo reale può essere rappresentato con diversi valori in diverse basi di dati.

- 1. Object Identification: si raggruppano in cluster tutte le tuple in tutte le risorse che corrispondono allo stesso oggetto.
- **2. Merging**: si sceglie come rappresentare ogni cluster.

Scelta: Metodo Probabilistico per Object Identification.

- 1. Normalizzazione dei formati
- 2. <u>Blocking</u> con riduzione dello spazio di ricerca: selezione di un sottoinsieme di campi.
- 3. Scelta della formula di distanza
- 4. Per un campione di record gia' accoppiati, calcola per ogni valore di distanza la frequenza di matching e di non matching
- 5. Calcola ora le distanze di ogni coppia degli insiemi A e B e costruisci la distribuzione delle frequenze delle coppie in funzione della distanza.
- 6. Scelta, a partire dalla distribuzione di cui al punto 4 di due distanze di soglia dmin e dmax

1. Normalizzazione dei formati

In questo caso, le coppie di attributi:

- Emergenza.TimeStamp e BloccoMezzo.Ora
- Emergenza.Data e BloccoMezzo.Data

Possono necessitare di un'operazione di normalizzazione per rappresentare le informazioni nello stesso formato.

2. <u>Blocking</u> con riduzione dello spazio di ricerca: selezione di un sottoinsieme di campi.

Si scelgono campi con stesso significato, abbastanza accurati e discriminanti.

Per la relazione Quartiere : Nome (l'unico attributo nella BD 2).

Per la relazione Emergenza e BloccoMezzo: Via, TimeStamp e Data.

Per la relazione SezioneVia e Sezione: Nome e Quadrante.

3. Scelta della formula di distanza

Si suppone di utilizzare la Distanza di EDIT.

Data una stringa s1 e s2 la distanza di EDIT tra s1 e s2 è quale al minimo numero di operazioni di cancellazione, sostituzione ed inserimento che devono essere fatte per trasformare s1 in s2.


4. Per un campione di record gia' accoppiati, calcola per ogni valore di distanza la frequenza di matching e di non matching

Quartiere 1	Quartiere2	Distanza	Stato
Porta Venezia	P.rta Venezia	1	match
San Cristoforo	S. Cristoforo	2	non match
		2	match
		3	non match
		1	match
		2	match
		4	non match
		0	match
		1	non match
		2	non match
		3	match
		4	non match
		5	non match
		3	non match




Distanza	Percentuale match
0	100%
1	66%
2	50%
3	33%
4	0%
5	0%


5. Calcola ora le distanze di ogni coppia degli insiemi A e B e costruisci la distribuzione delle frequenze delle coppie in funzione della distanza.



6. Scelta, a partire dalla distribuzione di cui al punto 4, di due distanze di soglia d_{min} e d_{max}



Vengono presentate alcune possibili query sullo schema Globale e si mostra la procedura di Unfolding che viene eseguita.



Query 1: Visualizzare tutti gli attributi di tutte le rilevazioni che provengono da uno specifico quartiere e che sono state effettuate dalla data '2010-12-31' alla data corrente.

SELECT Via, TimeStamp,

GradoNeve, GradoViabilità,

QuartiereResponsabile, IDResponsabile

FROM Rilevazione as Ril

WHERE Ril.QuartiereResponsabile = 'Quartiere1'

AND Ril.Data BETWEEN '2010-12-31'

AND GETDATE()

SELECT Via, TimeStamp,

GradoNeve, GradoViabilità,

QuartiereResponsabile, IDResponsabile

FROM SELECT Rilevazione. Via as Via,

Rilevazione.TimeStamp as TimeStamp,

Rilevazione.GradoNeve as GradoNeve,

Rilevazione.GradoViabilità as GradoViabilità,

Rilevazione.QuartiereResponsabile as

QuartiereResponsabile,

Rilevazione. IDR esponsabile as IDR esponsabile

FROM S1.Rilevazione

as Ril

WHERE Ril.QuartiereResponsabile = 'Quartiere1'

AND Ril.Data BETWEEN '2010-12-31'

AND GETDATE()

Query 2: Visualizzare l'ID, il quartiere e la via di tutte le squadre che hanno effettuato Rilevazioni con un GradoNeve maggiore o uguale a 3 oppure un GradoViabilità maggiore o uguale di 3.

SELECT S.ID,

S.Quartiere,

R.Via

FROM Rilevazione as R

INNER JOIN Squadra as S

ON Rilevazione. Via = Sezione Via. Nome

WHERE GradoNeve >= 3 OR GradoViabilità >= 3

```
SELECT S.ID,
           S.Quartiere,
           R.Via
FROM
                 SELECT
                           Rilevazione. Via as Via.
                           Rilevazione. TimeStamp as TimeStamp,
                           Rilevazione. Grado Neve as Grado Neve.
                           Rilevazione. Grado Viabilità as Grado Viabilità.
                           Rilevazione.QuartiereResponsabile as
                                    QuartiereResponsabile,
                           Rilevazione. IDResponsabile as IDResponsabile
                 FROM S1 Rilevazione
                  as R
           INNER JOIN
                 SELECT Squadra.Quartiere as Quartiere,
                          Squadra.ID as ID,
                          Squadra.#Squadra as #Squadra
                 FROM S1.Squadra
                  as S
           ON Rilevazione. Via = Sezione Via. Nome
WHFRF
           GradoNeve >= 3 OR GradoViabilità >= 3
```

Query 3: Visualizzare il Nome di tutte le Sezioni in cui, nell'intervallo di tempo che va dalla data '2010-12-31' ad oggi, vi sono state delle Emergenze con grado compreso tra 3 e 5 e visualizzare il numero di queste emergenze.

SELECT Nome,

COUNT(*)

FROM SezioneVia as S INNER JOIN Emergenza as E

ON SezioneVia.Nome = Emergenza.Via

WHERE E.Data BETWEEN '2010-12-31' AND GETDATE()

AND E.Grado BETWEEN 3 AND 5

GROUP BY S.Nome

```
SELECT
          Nome,
          COUNT(*)
        SELECT.
FROM
                     SezioneVia.Nome as Nome.
                                       SezioneVia.Quartiere as Quartiere.
                                       SezioneVia.#NumeriCivici as #NumeriCivici,
                                       SezioneVia.Via as Via,
                                       SezioneVia.Lunghezza as Lunghezza,
                                       'O' as GradoTraffico
                  FROM S1 SezioneVia
        UNION
                  SELECT
                                       Sezione.Nome as Nome.
                                       Sezione.Quartiere as Quartiere.
                                       SUM(Sezione.#NumeriDispari, Sezione.#NumeriPari) as #NumeriCivici,
                                       Sezione. Via as Via,
                                       Sezione.Metratura as Lunghezza,
                                       Sezione.GradoTraffico as GradoTraffico
                 FROM (S2.Sezione JOIN S1.SezioneVia) ON
                                                       S2.Sezione.Nome = S1.SezioneVia.Nome
      as S
      INNER JOIN
                  SELECT
                                                      Emergenza. Via as Via,
                                                      Emergenza.Data as Data,
                                                      Emergenza. TimeStamp as TimeStamp,
                                                      Emergenza. Grado as Grado,
                                                      Emergenza.GradoViabilità as GradoViabilità,
                                                      Emergenza.daQuartieri as daQuartieri,
                                                      Emergenza.daTrasporti as daTrasporti,
                                                      Emergenza. Via Rilevazione as Via Rilevazione,
                                                      Emergenza.TimeRilevazione as TimeRilevazione
                 FROM S1.Emergenza
        UNION
                  SELECT
                                                      BloccoMezzo.Via as Via.
                                                       BloccoMezzo.Data as Data,
                                                      BloccaMezzo.Ora as TimeStamp,
                                                      BloccoMezzo.GradoNeve as Grado.
                                                      BloccoMezzo.GradoMezzi as GradoViabilità.
                                                      O as daQuartieri.
                                                      1 as daTrasporti
                                                      NULL as ViaRilevazione,
                                                      NULL as TimeRilevazione
                 FROM ([[[BloccoMezzo JOIN Sezione] ON BloccoMezzo.Via = Sezione.Nome]
                                      JOIN PosizioneMezzo] ON Quartiere = PosizioneMezzo.Corso]
                                                      JOIN MezzoPubblico) ON Mezzo = MezzoPubblico.ID)
                 WHERE diSuperficie = T
         as E
      ON SezioneVia.Nome = Emergenza.Via
WHERE E.Data BETWEEN '2010-12-31' AND GETDATE() AND E.Grado BETWEEN 3 AND 5
GROUP BY S.Nome
```